

SmartFarm AI · Phase 2 (Deep Learning)

잎 병해 3분류·위치 검출(CNN·YOLO) + 환경 시계열 예측(LSTM)

전이학습 3분류 · Grad-CAM 설명가능 AI · YOLO 검출 · 다변량 LSTM

PyTorch (Apple MPS) · 토마토 정상·잎곰팡이병·황화잎말이 3분류 · ImageNet·YOLOv8 재사용

발표자 : 2팀 정재봉 · 작성일 : 2026.06.29

0.97

3분류 val acc

0.78

검출 mAP@50

0.997

ROC-AUC

1.18°C

LSTM MAE

목차

01 문제 · 데이터 · EDA p3

03 CNN 기초 · 전이학습(3분류) p7

05 평가 — 혼동행렬 · ROC/AUC p12

07 부위 게이트 — 과육 OOD 방어 p15

09 LSTM 다년 시계열 p17

11 다음으로 — Phase 3 (LLM) p21

02 방법 — 5단계 파이프라인 p6

04 학습곡선 · 불균형 대응 p9

06 Grad-CAM 설명 (+한계) p13

08 YOLO 위치 검출 p16

10 트러블슈팅 · 성과·배운점 p19

정형 ML로는 못 푸는 일을 DL로



이미지

앞 사진으로 병 진단 — 픽셀 패턴은 표로 못 만든다 → CNN 필수



순서

환경(온도·습도)의 흐름을 예측 — 시점 간 의존 → LSTM



명분

"ML이 못 하던 걸 DL이 한다"를 한 프로젝트에서 직접 실증

토마토 잎 3종 + 환경 8변수 시계열

비전

AI Hub 시설작물 질병진단(071) 토마토 잎 3분류(정상·잎곰팡이병·황화잎말이) · 071 부위 라벨(area) 전량 활용 +
질병 Train 확보 · 분류 train 3,255·val 691, 검출 train 346·val 87

시계열

농진청 환경 일별 8변수(내부온도4·습도·CO₂·외부온도·일사량) · 485개 시계열(2022~24 다년) 통합(과거 7일 → 다음날)


처리

분류 224×224·ImageNet 정규화 / 검출 라벨 JSON(박스+병종 코드)→YOLO 변환 / 시계열 시간순 분할(누수 차단)

데이터를 먼저 본다 — '정상'이 다 잃은 아니었다

데이터 탐색(EDA) — 토마토 잎 3종 + 환경 시계열
(샘플 사진: PlantVillage CC0)

클래스 분포(정제 후) — 정상(잎) 1000 · 질병 1956
정상=잎(area3)만 선별 + 질병 Train 확보 → 균형 데이터



샘플 — 황화잎말이




샘플 — 정상




샘플 — 잎곰팡이병



대표 농가 환경 시계열



내부온도 분포(전체 농가)



**정제 후 정상(잎) 1330 ·
질병 2616**

초기 가용분은 정상≫질병(≈18:1)이었지만, 원천 '정상'에 과실·꽃·줄기가 혼재(부위 라벨로 확인)·질병 Train 확보 → 잎(area3)만 선별해 균형 데이터 구축. 우측은 클래스별 샘플 잎·환경 시계열·내부온도 분포.

데이터 정제 — 정상 원천에 잎 외 과실·꽃·줄기가 섞여 있었다 → 잎만 normal 로 선별 · 질병은 Train 추가 확보(246→2616장)로 균형화

전이학습 → 평가 → 설명 → 검출 → 시계열

전이학습

ImageNet 백본 **freeze** + head 교체 → 정상·잎곰팡이·황화잎말이 **3분류**

불균형·평가

클래스 가중치로 소수 질병 recall ↑ · 3×3 혼동행렬 · ROC/AUC · FN 분석

부위 게이트

부위 분류기(과실·꽃·잎·줄기)로 **잎이 아니면 진단 차단** → 과육 오분류 방지(OOD 방어)


Grad-CAM

어느 병반을 보고 판단했나 히트맵 → **설명가능 AI**(한계까지 직시)

YOLO·LSTM

YOLOv8n 병해 잎 **위치 검출** · 다변량 LSTM **다음날 온도 예측**(2022~24 다년·baseline 대비)


필터가 무늬를 "따로따로" 본다



FashionMNIST 정확도
0.87

conv1 특징맵 — 필터마다 가장자리·질감 등 다른 부분에 반응. 한 필터(3×3)를 이미지 전체에 공유해 위치와 무관하게 같은 특징을 잡는다.


정제된 데이터로 99% — 사전학습의 힘



resnet18 0.971 ·
mobilenet_v2 0.987

토마토 3분류(정상·잎곰팡이병·황화잎말이)로 백본 2종 비교. backbone은 얼리고 head만 학습. **앞만 정제 + 질병 데이터 확보**로 0.94→0.97·0.99 향상 — 데이터 품질이 성능을 끌어올렸다.


실험을 기록·비교해 모델을 고른다 — MLflow



resnet18 0.971
mobilenet_v2 0.987

앞의 백본 비교를 눈대중으로 끝내지 않고, 백본·하이퍼파라미터(lr·epochs·optimizer)와 val 정확도를 MLflow로 자동 추적·비교. **mobilenet_v2(0.987)**가 **resnet18(0.971)**보다 정확하지만, Grad-CAM 설명(layer4 혹은) 호환을 위해 서빙 모델은 resnet18을 채택 — 정확도와 설명가능성의 trade-off를 근거 위에서 결정.

건강하게 학습됐는가 — loss↓ acc↑




val acc 0.96 → 0.97

전이학습 epoch별 train loss(↓)와 val accuracy(↑). 데이터가 충분해 1 epoch부터 0.97, loss 단조 감소하며 val acc 0.98로 수렴(발산·과적합 없음) — 안정적 학습.

농치던 질병을 잡아낸다 — 클래스 가중치의 효과

클래스 가중치 효과 — 소수 질병(잎곰팡이·황화잎말이) 놓침 줄이기



질병 recall 0.86/0.93 → 0.96/0.98

정상 다수 + 소수 질병(잎곰팡이·황화잎말이)으로 불균형을 연출하고 클래스 가중치 유무를 비교 — 대응 전 recall $\approx 0.2 \rightarrow$ 대응 후 ≈ 0.9 . (다음 장의 종합 평가가 아니라) 불균형 '대응'의 효과로, 전체 정확도가 아니라 소수 질병 recall로 봐야 '놓친 병'이 보인다.


단서 — 가중치 X 잎곰팡이 0.86·황화잎말이 0.93 $\rightarrow$ O 0.96·0.98 · 데이터가 풍부해져 효과는 축소(정상 recall 0.99 $\rightarrow$ 0.94로 희생되는 trade-off)

정확도 너머 — 3×3 혼동행렬·ROC·FN

혼동행렬

	leaf_mold	normal	tylcv
실제			
leaf_mold	218	5	2
normal	6	224	3
tylcv	3	1	229
	leaf_mold	normal	tylcv

예측



**3분류 acc 0.97 · AUC
0.997**


3×3 혼동행렬로 두 병종까지 구분(잎곰팡이↔황화 잎말이 혼동 적음), 질병 vs 정상 ROC/AUC로 검출력 정량화, FN(병→정상) 사례를 직접 분석.

"어디를 보고" 병이라 했는지 검증


입력 — leaf_mold 예시 (PlantVillage CC0)



Grad-CAM — 모델이 '어디를 보고' 그 클래스로 판단했나
Grad-CAM 히트맵



오버레이 (예측 leaf_mold)



진단 근거 시각화

마지막 conv 활성화 × 클래스 기울기 → 히트맵을
앞 위에 겹침. 이 예시는 잎곰팡이를 정상으로 놓친
FN 케이스 — 히트맵이 병반을 못 짚었음을 보여준
다.

히트맵을 의심하라 — Grad-CAM의 한계

주의 ① 히트맵이 병반이 아닌 **비병변 영역(잇맥·배경·촬영 마커)**에 반응할 수 있어, 근거가 항상 옳지는 않다

주의 ② 마지막 conv(저해상도)를 키운 것이라 **위치가 거칠다** — 정밀 국소화가 아닌 '대략 어디'

대응 사람이 검수하는 **보조 지표**로만 사용 · 정밀 위치는 다음 단계 **YOLO 검출**로 보완

참고문헌 Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks", ICCV 2017

과육을 병이라 하지 않게 — 부위 게이트

부위 게이트 — 잎이 아니면(과실·꽃·줄기) 잎 진단을 차단(과육 오분류 방지)

부위 분류기 혼동행렬 (val) — 정확도 0.932

실제 부위	예측 부위			
	꽃	과실	잎	줄기
꽃	17	0	1	2
과실	0	16	0	5
잎	0	0	72	3
줄기	0	0	2	73

과육 사진 → 과실 (38%) → 잎 아님 → 진단 차단
(Wikimedia Commons, CC BY-SA 3.0, Ravedave)



부위 분류 0.932

닫힌 3분류기는 잎이 아닌 사진도 한 클래스로 찍어 과육을 병으로 오진한다. 부위 분류기(과실·꽃·잎·줄기)를 앞단에 뒤 '잎이 아니면 진단 차단' — 문제의 과육 사진도 '줄기'로 분류돼 차단됐다.

데이터 정제의 부산물 — 071 부위 라벨(area)을 살린 덕에 추가 학습 없이 과육 OOD를 방어


병든 잎이 "어디" 있는지까지

YOLO 토마토 병해 잎 검출 — 박스 위치 + 진단
(PlantVillage CCO 이미지)

leaf_mold 예시




tylcv 예시



normal 예시 1




normal 예시 2



mAP@50 0.78

사전학습 YOLOv8n을 토마토 3클래스(정상·잎곰팡이·황화잎말이)로 전이학습. 분류는 '무엇'만, 검출은 장면에서 잎을 찾아 박스 위치 + 병종 라벨 + 신뢰도까지 — 비전 파트의 마지막 두께.

다변량·다중 시계열로 baseline을 이기다




**MAE 1.18°C < baseline
1.25°C**

환경 8변수(외부온도·일사량·CO₂...) + 485개 시계열 통합(2022~24 다년) 학습으로 다음날 내부온도 예측. 단변량으로는 못 이기던 persistence baseline(1.25°C)을 LSTM(1.18°C)이 앞섰다.

단변량·시계열 1개로는 baseline을 못 이김 → 다변량 + 485개 농가 시계열 통합으로 역전. 'baseline과 비교해야 진짜 성능이 보인다'

데이터를 늘리니 더 정확해졌다 — 단년 vs 다년



**198→485 시계열 · MAE
1.22→1.18°C**

환경 데이터를 2022 단년 → 2022~24 다년으로 확장하자 시계열이 198→485개(2.4배)로 늘고, LSTM MAE가 1.22→1.18°C, baseline 대비 우위도 +0.05→+0.07°C로 커졌다.

Phase 1(작물 분류)의 '데이터 양 효과'가 시계열에서도 일관되게 재현 — 재현: `python src/dl/compare_years_lstm.py`

막혔던 곳들 — DL 트러블슈팅

문제	원인	해결
질병 val 0장	원천이 Validation 구조뿐 · 소량일 때 분할 실패	<code>prepare</code> 에 80/20 분할 대응
Grad-CAM 히트맵이 안 나옴	backbone freeze로 conv층까지 grad가 안 흐름	입력 <code>requires_grad + retain_grad</code> 로 경로 확보
앞 아닌 사진 오진단 · 병든 잎 오차단	닫힌 3분류기 강제분류 · YOLO 게이트 분포 불일치	ImageNet 식물판별 <code>plant_score(0.04)</code> 게이트로 교체
과육을 병으로 오진	정상 데이터에 잎·과실·꽃·줄기가 혼재	부위 게이트로 차단 (→ 15p)

성과 종합 & 배운점

단계	지표	값
전이학습	토마토 3분류 (서빙 resnet18)	0.97
부위 게이트	과실·꽃·잎·줄기 분류 (OOD 방어)	0.93
YOLO 검출	병해 잎 위치 mAP@50	0.78
불균형 대응	소수 질병 recall	0.86 → 0.96
평가	3분류 ROC-AUC	0.997
시계열	LSTM MAE / baseline	1.18 / 1.25°C

배운점

- 전이학습 3분류(정상·잎곰팡이·황화잎말이) — 라벨을 끝까지 활용
- Grad-CAM 설명·한계 직시 + YOLO 검출 — "진단 → 근거 → 위치"로 비전 완성
- 다변량·다년(2022~24) 시계열로 LSTM이 baseline을 이김 — 데이터 양 효과 + 비교 평가



배포: Streamlit (app/phase2_dl.py) — 진단+Grad-CAM 탭 · YOLO 검출 탭 · 모델 → models/ (Phase 3 LLM이 로드)

숫자·라벨을 "말"로 — 자연어 처방 + 알림

CNN 진단 + LSTM 예측 + 재배가이드(RAG) → LLM 자연어 처방 → 🔔 알림

3-1 Claude API

진단·예측 숫자/라벨 → 자연어 처방 생성

3-2 RAG

농사로 재배가이드 검색 → 근거 있는 조언

3-3 통합 파이프라인

ML/LSTM 예측 + CNN 진단 + RAG → 처방 통합

3-4 알림·대시보드

텔레그램 알람봇 + Streamlit 통합 대시보드

처방 예시 🐼 잎곰팡이병 의심(87%) — 감염 원 제거·습도↓ · 💧 토양수분 30% 낮음 — 관수 · 🌡️ 2시간 뒤 32℃ — 환기 준비