

SmartFarm AI · Phase 3 (LLM)

숫자·라벨을 "사람 말"로 — 재배 도우미(예방 코치 + 병충해 확인 + 자연어 처방)

Ollama 로컬 function calling · 농사로 RAG · 환각 방어 3종 · 규칙 기반 관제

Ollama qwen2.5:14b(처방)·bge-m3(RAG) · 농사로/NCPMS 코퍼스 4문서 · 디스코드 Webhook 알림

발표자 : 2팀 정재봉 · 작성일 : 2026.07.06

-95%

처방 fast-path(서버)

근거 인용

RAG 출처 코드 주입

3종

환각 방어 장치

매시

자동 감시·알림

목차

01 문제 · Problem

03 입력 — ML/DL 산출물

05 설계 — RAG(농사로)

07 시간축 처방 (진단 × LSTM)

09 fast-path 아키텍처 (-95%)

11 확장 — 환경 관제 (오늘 운영)

13 환경 관제 — 중앙 유지형 제어 ★

15 산출물 — LLM 실험 기록 3부작

17 마무리 — 전체 파이프라인

02 컨셉 — 재배 도우미 loop

04 설계 — function calling

06 환각 방어 3종 ★

08 모델 선택 여정 (14b→7b→벤치→역할분리)

10 자동 감시 · 알림

12 환경 관제 — 오늘 차트 · 사전 경보

14 완성도 — UI 리뉴얼(다크/라이트)

16 트러블슈팅 8선

18 결과 · 배운점 · 향후 발전

센서·사진 한 장이 처방·관제까지 — 한 흐름으로



진단·예측 = ML/DL · 설명·처방 = LLM · 관제 = 규칙 — 역할을 분리해 환각을 구조로 막는다.

라벨·숫자만으론 초보자가 못 움직인다



진단만

CNN은 "앞곰팡이병 87%"만 뱉음 — 원인·조치를 모른다



예측만

LSTM은 "내일 내부온도 32°C"만 뱉음 — 그래서 뭘 해야 하나



생물 특성

작물은 내 뜻대로 안 됨 → 초보자는 "이게 병충해가 맞긴 한 건지"부터 헛갈림



분업 원칙(불변)

진단은 ML/DL, 설명·처방·코칭은 LLM — LLM에게 진단을 시키지 않는다(환각 위험)

DL 진단을 "확인 단추"로 재정의

A 일일 코치 평상시 — 매일 "오늘 할 일"(LSTM 환경 예측 기반)

B 조기 경보 이상 징후 — 환경×질병위험 → "지금 잎 확인해봐요"

 **DL 진단** 확인 — 잎 사진 → 병충해 맞는지 확인(CNN·게이트·YOLO)

C 안심/처방 정상 → 안심("괜찮아요, 물자국이에요") · 질병 → 처방+용어풀이+RAG 근거

D 대화형 Q&A 후속 — "약 없이 환경으로만 잡을 수 있어요?"

Phase 1(ML)·Phase 2(DL)가 넘겨주는 것

 **환경 예측** 다음날 내부온도·추세 — Phase 2 LSTM(토마토 전용, MAE 1.18°C < baseline) / Phase 1 계열 기대값 회귀(XGB MAE 1.11°C)

 **잎 진단** 라벨+확률 — Phase 2 CNN(resnet18) 4분류(정상+잎병 3종) acc 0.96

 **입력 게이트** OOD/부위 판정 — "잎 아님" 차단·"과실" 차단

 **병변 위치·근거** YOLOv8n 박스 리스트 + Grad-CAM 히트맵

 **재배 지식** 농사로/NCPMS 방제 가이드 chunk (bge-m3 임베딩 RAG)

자연어로 풀어 넣지 않고 구조화 입력으로

`get_forecast()` { next_temp, trend, humidity_risk } — 일일 코치·조기 경보(A·B)

`get_diagnosis()` { label, prob, probs{4종}, part, ood_blocked } — 확인 단추

`get_detection()` { boxes:[{cls, conf, region}], lesion_count } — 병변 위치

왜 구조화인가 DL 결과를 "풀어 쓴 문장"이 아니라 **tool 입력**으로 넘기면, tool 실패까지 모델에 되먹여 복구 가능

근거 있는 조언 — 잎병 3종 범위

코퍼스

농사로 재배·방제 가이드 **잎곰팡이병·황화잎말이·잎마름역병**(+토마토 일반 재배) 4문서

흐름

진단 라벨/질문 → chunk 검색(bge-m3 임베딩·코사인 유사도) → 근거로 프롬프트 결합 → 처방에 **출처 인용**

스코프가 품질

disease 라벨로 검색 범위를 한정하고, 매칭 없으면 **빈 결과 반환** — 엉뚱한 병해 근거 주입 방지

근거출처는 코드가 채움

LLM 출력에서 받지 않고 RAG 검색 결과로 **코드가 직접** 채워 환각 배제

"AI가 모를 땐 모른다고 말하게"

① 신뢰도 톤 분기 prob 구간별 강도 조절 — 고확신(>0.8)=단정·즉시 방제 / 애매(<0.6)=단정 금지·정밀 확인 권유

② 게이트 차단 사유 안내 차단 시 그냥 막지 않고 왜·어떻게 다시 찍을지 안내("과실 사진이라 앞병 진단 불가 → 앞 뒷면을 밝은 곳에 서")

③ 클래스 한정성 자기인식 모델이 아는 범위(앞병 3종+정상, 4종뿐)를 system 프롬프트에 고정 — 범위 밖 질문엔 "진단 보류"라고 정직하게

+ 구조 강제 근거출처는 코드 주입, format= JSON 스키마 강제 + 검증 재시도 — 프롬프트 지시보다 확실

진단 단독이 아니라 환경 예측과 교차

교차 처방

앞곰팡이병(고습 악화) + LSTM 야간 고습 예측 → "오늘 밤 제습기 가동, 새벽 결로 위험"

대상

습도 민감 병해(앞곰팡이병·앞마름역병) 진단 시 환경 예측을 교차 주입

의미

ML(환경 예측)+DL(진단)+LLM(처방) 세 단계가 **한 문장**에서 만남

출력 형식

{ 진단요약, 원인, 즉시조치, 예방, 재촬영시점, 근거출처[] } — 고정 스키마로 Streamlit 카드·디스코드 메시지가 같은 소스 사용

모델 약점을 아키텍처로 무효화했다

① 로컬 채택

qwen2.5:14b

한국어 + function calling이 오픈모델 중 안정적 — 처방 agentic 경로 기본 모델로 채택

② 서버 제약

qwen2.5:14b → 7b (서버만)

OCI가 GPU 없는 3코어 ARM CPU·16GB — 14b는 서버에서 무리 → `OLLAMA_MODEL` env로 서버만 7b 강등(로컬은 14b 유지)

③ 후보 벤치

7b조차 CPU에서 UX 불성립 — 처방 342초

이슈 #18 벤치: **qwen2.5:3b** 10.5 tok/s·처방문 품질 ⚠ (원인 서술 어색, "재촬영시점" 동문서답) vs **exaone3.5:2.4b** 13.0 tok/s·더 작는데 더 빠르고 한국어 처방 품질 우수(근거·예보 수치 정확 반영)

④ 핵심 제약과 해법

exaone은 function calling이 약함

이 제약을 fast-path(1-call)가 tool calling 자체를 없애 무효화 → exaone은 "작성 전용(writer)"으로만 채택

최종 구도(역할별 모델 분리) — 로컬 처방·agentic Q&A = **qwen2.5:14b**(tool calling 경로) · 서버 처방문 작성 = **exaone3.5:2.4b**(`OLLAMA_WRITER_MODEL`, 1-call 전용) · 서버 tool calling 경로 = **qwen2.5:7b** 유지

342.6초 → 16.2초(-95%), 웹 28초 → 17~19초(-35%)

이슈 #15 지연 개선

tool 라운드 num_predict 캡 + keep_alive 30m(콜드 재적재 제거) + 프롬프트 다이어트(-17~20%) → 로컬 웹 28초 → 17~19초(-35%), 남은 대기는 st.status 단계별 진행 표시로 보완

이슈 #18 fast-path 전환

OCI(3코어 CPU) 서버에서 tool 라운드 2회=342초 → 진단·RAG·예보를 코드가 직접 실행, LLM은 최종 JSON 처방 1-call만(writer=exaone3.5:2.4b)


결과

서버 342.6 → 16.2초(-95%), 로컬 10~15초 — 환각 방어·근거 코드 주입은 그대로 유지

경로 보존

agentic(tool calling) 경로는 CLI·날씨 Q&A에 그대로 보존(대화형 D는 유연성이 더 중요)

확인 → 처방 → 디스코드 알림까지



앱 «AI 처방» — 게이트→진단→function calling→RAG 근거→구조화 처방



디스코드 식물 알림 — 장치 전환·긴급·사전 경보(예보 기반)

monitor.py · notify.py · systemd 매시

`src/llm/monitor.py`가 가상센서 스트림을 재생해 임계 판정 시 레벨 전이 시만 디스코드 Webhook 발송(중복방지·전송 실패 재시도). 우측 식물 캡처는 «오늘 운영»의 장치 전환·긴급·사전 경보 3종이 실제 발송된 모습 — 매시 systemd 타이머가 상주 감시한다.

LLM 처방 옆에 규칙 기반 관제 — 분업 확정

장치 4종 · 온·습도 중앙 유지형
P-제어 · 매시 알림

앱 <<환경 관제>>를 규칙 기반으로 전환. 오늘 운영 모드 — KMA 예보로 오늘 기준선을 잡고, 장치 4종 (제습기·가습기·쿨링팬·히터)을 온·습도 중앙 유지형 P-제어로 돌린 뒤 매시 디스코드 알림. KMA 장애는 폴백·재시도로 흡수.

진단·처방은 LLM, 관제는 규칙으로 분업 확정.

환경 관제

오늘 실제 운영 상태와 시뮬레이션을 한 화면에서 확인해요.

오늘 운영

시뮬레이션

외부 온도(실황)
25.5°C

실내 온도(제어 없음)
27.4°C

실내 온도(제어)
26.8°C

작동 중 장치
가습기, 쿨링팬

지금 이후 값은 기상청(KMA) 예보 기반 예측이에요 — 매시 자동 갱신돼요.

설정 밴드

히스테리시스 데드밴드로 장치가 경계에서 깜빡이지 않게 해요.

온도 밴드(°C)

21.00 30.00

습도 밴드(%)

60.00 80.00

장치

자동 모드는 설정 밴드에 따라 자동으로 켜지고 꺼져요. 수동으로 전환하면 오늘 운영 판정에도 그대로 반영돼요.

제습기

OFF · 자동

자동 모드

가습기

ON · 자동

자동 모드

쿨링팬

ON · 자동

자동 모드

히터

OFF · 자동

자동 모드

실행은 빨강, 계획은 회색 — 오늘 하루가 한눈에



실행 빨강 · 계획 회색 점선 ·
사전 경보

오늘 0~24시 온·습도 차트 — 실행(빨강 실선) vs 계획(회색 점선)을 색으로 분리하고, 0시는 어제 값에서 이어진다. 아래엔 제어 이벤트 표와 알림 분기 — 현재=🔴 긴급 / 미래=🔮 사전 경보 / 과거=미발송. 과거는 스냅샷 누적, 미래는 예보로 합성해 그린다.

밴드 끝이 아니라 '중앙'을 잡는다 — 온·습도 통일


문제 여름 고습이 지속되면 '밴드 밖에서만 ON' 규칙이 값을 밴드 상단(74~85%)에 가둠 — 중앙 위 정체(온도도 겨울 하한 정체로 대칭)

원인 P-제어 수식이 아니라 **ON 진입 기준(밴드 경계)**이 문제


해결 · 중앙 유지형 ON/OFF를 **밴드 중앙(mid) 기준** 히스테리시스로 통일(온·습도 모두) — '실내를 일정하게'가 스마트팜의 이점

검증 · 계절 lean 여름(27.5°C·92%)→**22.7·71%** · 겨울(15°C·40%)→**22.3·69%** 중앙 수렴 — 여름=위에서·겨울=아래에서 복원(이슈 #51)

야외 가독 + 관제실 무드 — 다크 기본 · 라이트 토글



딥그린 다크(기본) — 관제실 무드 · 큰 숫자 · 상태색



라이트 토글 — 띄약별 야외 가독(순백 대비)

다크 기본 + 라이트 토글 · KPI=제어 후 값

순정 Streamlit 룩에서 디자인 시스템(딥그린 다크 기본 + 라이트 토글)으로 전면 개편 — 헤더 그린 띠·아이콘 원 KPI·상태 칩·채운 경보 배너. 핵심 지표는 관제 오늘 운영(제어 후) 값과 연결하고 경보도 제어 후 값 기준으로 일관화(이슈 #47·#48·#51·#55).

ML · DL · LLM — 실험 기록 3부작 완성

서비스

농장 대시보드

임 병해 진단

AI 처방

환경 관제

작물 환경 추천

프로젝트 기록

프로젝트 개요·성과

ML 실험 기록

DL 실험 기록

LLM 실험 기록

라이트 모드

LLM 실험 기록

Ollama 로컬 LLM(qwen2.5:14b) 기반 재배 도우미(처방·코치-RAG 상담) 실험 기록(Phase 3) — 정량 figure 대신 서술형 결과·지연 개선 수치-RAG 코퍼스 통계로 구성해요.

재배 도우미 결과 요약

- 처방(C): 일 사진 → 게이트 → 진단 → function calling → RAG 근거 → 구조화 JSON 처방. 근거 출처는 LLM이 아니라 코드가 채워 환각을 배제하고, 스키마 위반 시 1회 재시도 후 안전 폴백해요.
- 일일 코치(A): 초기 경보(B): LSTM 환경 예측을 기반으로, 습도 위험이 있을 때 RAG 근거를 경보에 주입해요.
- 시간축 처방: 습도 민감 병해(잎곰팡이병·잎마름역병) 진단 시 환경 예측을 교차 주입 — ML+DL+LLM이 한 처방에서 만나요.
- 환각 방어 3층 — ① 확신도(prob) 구간별 톤 분기(고확신 단정 / 애매 확인 권유) ② 게이트 차단 시 원인·재활영법을 함께 안내 ③ 모델이 아는 클래스 범위(일병 3종+정상)를 system 프롬프트에 고정해 범위 밖 질문은 정직하게 '진단 보류'로 답해요.
- 자동 감사: 가상센터 스트림을 재생해 일기 편집 후 디스코드 Webhook으로 알림(레벨 전이 시만 발송, 전송 실패 시 재시도)해요.

처방 지연 개선

로컬 웹 처방(이슈 #15)

17~19 초

28초 → 약 -35%

서버 fast-path(이슈 #18)

16.2 초

342.6초 → -95%

로컬(웹 기준): tool 라운드 num_predict 캡 + 모든 Ollama 호출 keep_alive=30m(풀드 재적재 제거) + 프론트 다이얼트(-17~20% 토큰). 서버(OCI 3코어 CPU): 진단-RAG-예보를 코드가 직접 실행하고 LLM은 최종 JSON 처방만 1-call로 작성하는 fast-path + writer 모델 분리(서버 exaone3.5:2.4b).

RAG 코퍼스 통계

코퍼스 문서

4 개

검색 chunk

15 개

병해 커버리지

4 개

ML/DL/LLM 3부작 · 서술+통계 구성

《프로젝트 기록》에 ML·DL과 나란히 LLM 실험 기록 페이지 신설. 정량 figure가 없는 특성상 서술형 요약 + 처방 지연 개선(342.6→16.2초) + RAG 코퍼스 통계로 구성.

Phase 1·2·3 실험 기록 페이지로 포트폴리오 통일.

막힌 지점 → 원인 → 해결, 8가지

상황	원인	해결
처방 342초(서버)	tool 라운드 낭비 + 콜드 재적재	캡·keep_alive·프롬프트 다이어트(-35%) → fast-path 1-call+writer 분리(-95%)
exaone function calling 약함	소형 모델의 tool 선택 신뢰도 부족	모델 교체가 아니라 fast-path로 tool calling 자체를 제거(아키텍처 해결)
관제 1차 구현 방향 어긋남	2024 리플레이 기반으로 구현 — 의도(오늘 날짜 운영)와 불일치	스펙 재확인 후 오늘 운영 모드로 재설계(이슈 #23)
장치 효과가 안 보임	1일 델타÷24=시간당 -0.2%p로 제어 반응 무의미	시간당 상수(±2℃/±8%p)+관성(누적) 제어+관통 방지 클램프 — 채터링 9회→3회 이하 실증(이슈 #27)
KMA 간헐 타임아웃(OCI)	10초 초과 응답이 2연속 발생	60초 캐시 + 직전 성공 데이터 폴백(stale-while-error) + 재시도 3회(이슈 #29 완료)
오늘 차트 과거 구간 증발	KMA 예보는 발표분 이후만 제공 + 시간별 기록 부재	매시 스냅샷 누적 + 과거=기록·미래=예보 합성(이슈 #40)
습도 중앙 위 정체	'밴드 밖에서만 ON' + 한쪽 외란(여름 고습)	ON/OFF를 밴드 중앙 기준 히스테리시스로 통일 → 중앙 수렴·계절 lean(#51)
라이트 글자·탭 색 실종	다크 base textColor 잔존 + 오버라이드가 탭 라벨에 직접 매치	네이티브 텍스트 잉크색 오버라이드 + 탭 color:inherit(캐스케이드, #48)

ML → DL → LLM, 한 흐름으로 완성

센서/사진 → Phase1 ML + Phase2 DL(진단·예측) → Phase3 LLM(function calling+RAG+환각방어) → 처방·코칭·관제·알림

① 쉽게 키우기 일일 코치(A)·오늘 운영 관제로 평소 챙겨줌

② 병충해 탐지 확인 단추(DL)로 사진 확인 → 처방·안심(C)

다리 조기 경보(B)가 환경×질병위험을 이어줌

정직성 잎병 3종(+정상) 범위 — 게이트로 범위 밖은 차단·보류

처방 예시 🐛 잎곰팡이병 의심(87%) — 오늘 밤 결로 위험, 제습기 가동 · 📖 근거: 농사로 방제 가이드 · 🛠️ 관제: 제습기 자동 ON · 🔔 디스코드 알림 발송

성과 종합 & 배운점

단계	지표	값
처방 지연	로컬 웹 (이슈 #15)	28 → 17~19s (-35%)
처방 fast-path	서버(OCI) (이슈 #18)	342.6 → 16.2s (-95%)
환경 예측	LSTM MAE / baseline	1.18 / 1.25°C
기대값 회귀	XGB MAE(내부 온도/습도)	1.11°C / 7.39%p
진단 입력	resnet18 4분류 acc	0.96
환경 관제	중앙 유지형(온·습도)	여름 71% / 겨울 69% 수렴

배운점

- 환각은 프롬프트가 아니라 구조로 막는다 — 근거출처 코드 주입 + format= JSON 스키마 강제 + 검증 재시도
- function calling은 "자연어로 풀어 넣기"의 상위호환 — tool 실패까지 모델에 되먹여 복구 가능
- RAG는 스코프가 품질 — 라벨로 검색 범위를 한정, 매칭 없으면 빈 결과 반환(엉뚱한 근거 주입 방지)
- 로컬 LLM 지연은 모델 크기보다 "낭비"부터 — 버려지는 생성 캡·콜드 재적재 제거·프롬프트 다이어트로 품질 손실 없이 단축
- 알림은 dedup이 본체 — 레벨 전이 시만 발송 + 실패 시 재시도

시물로 파이프라인 완성 — 다음은 실센서·실증

실 IoT 센서 연동 가상 센서(2024 리플레이) → 실제 온습도·CO₂·조도 스트림 — 센서 어댑터 계층이 분리돼 교체 지점 명확

예측 기반 선제 제어 규칙 반응 제어 → LSTM 예보로 미리 가동(폭염 예보 시 선제 냉방) — feed-forward

에너지·비용 인지 제어 중앙 유지가 장치 가동을 늘리므로, 전기요금 시간대·허용 밴드를 고려한 비용 최적 제어

작물·병해 확장 토마토 전용 → 다작물(고추·오이) + 병해 중증도 등급 · 해충 탐지

Discord 봇(양방향) 현재 Webhook 단방향 알림 → 봇 명령으로 상태 조회·처방 요청 등 대화형(LLM Q&A 경로 재사용)