

SmartFarm AI · Phase 1 (Machine Learning)

환경 센서로 재배 작물 9종 분류 + 정직한 평가·데이터 누수의 교훈

정형 ML(XGBoost) · 평가 3겹(GroupKFold) · 다년 결합 '데이터 양 효과'

scikit-learn · XGBoost · 농진청 스마트팜 현장 농가 3개년(2022~24) · 288만 시간별 → 11.6만 일별 집계

발표자 : 2팀 정재봉 · 작성일 : 2026.06.30

0.68

test F1(macro)

0.49

GroupKFold F1

9종

작물 분류

+0.073

다년 결합 효과

목차

01 문제 — 환경값에서 '의미'를 읽다

p3

03 EDA — 25배 불균형 · 환경 차이

p5

05 모델 비교 — 트리 vs 선형

p8

07 피처 중요도 · 작물별 성능

p10

09 트러블슈팅

p13

11 다음으로 — Phase 2 (DL)

p15

02 데이터 — 농진청 3개년 · 9작물

p4

04 방법 — 집계·피처8·평가 3겹

p7

06 ★ 평가 3겹 — 데이터 누수

p9

08 ★ 데이터 양 효과 — 단년 vs 다년

p12

10 결과 · 배운점

p14

환경값에서 "무슨 작물인지"를 읽다

 **현황** 스마트팜 대시보드는 **현재 환경값**(온·습도·CO₂·일사)만 보여준다 — 그 숫자가 어떤 작물의 재배환경인지는 못 읽는다

 **과제** 환경 센서 통계 → **재배 작물 9종 분류 ML** — 스마트팜 데이터에 '의미'를 붙이는 1단계

 **명분** 노지 입문(공개 데이터)에서 **국내 시설재배 실데이터**로 — Phase 2(잎 진단)·Phase 3(처방)로 관통할 토대

농진청 3개년 환경 + 작물 9종

출처

농촌진흥청 스마트팜 현장 농가 데이터(공공데이터포털) · 농가 48곳 · 2022~2024 3개년 결합


규모

약 288만 행(시간별) → 농가·작가·작물·일자 일별 집계 11.6만 행(노이즈↓·행수↓)

작물

9종(완숙·방울토마토·딸기·오이·참외·파프리카·가지·국화·수박) · 불균형 25배 · 수박은 2023부터 등장 → 다년 결합으로 신규 커버

데이터를 먼저 본다 — 25배 불균형




방울토마토 25,241 vs 수박 1,023

작물별 표본 수 — 방울토마토 25,241 » 수박 1,023(약 25배). 소수 클래스(수박·국화·가지)는 Accuracy로는 놓치기 쉬워 F1(macro) 중심 평가가 필수.

불균형 근거 — 작물마다 농가·작기 수가 다름 → Accuracy 함정 회피 위해 macro-F1·per-class recall로 평가 설계

작물마다 선호 환경이 다르다 — 분류의 근거

작물별 주요 환경값 평균 비교



작물별 환경 프로파일 분리

작물별 환경 평균 비교 — 딸기는 낮은 온도·높은 습도, 참외는 높은 일사량, 파프리카는 CO₂가 높다. 이 환경 차이가 "환경값만으로 작물을 구분"할 수 있다는 가설의 근거.

단, 환경은 농가가 제어하는 값이라 작물 고유 신호는 약함 → 새 농가 일반화의 본질적 한계로 이어짐(\$결과)

집계 → 피처 8종 → 모델 3종 → 평가 3검

집계·전처리

시간별 → 일별 통계 집계 · 내부 온도(평균·최저·최고·표준편차)·습도·CO₂·외부온도·일사량 피처 8종

누수 차단

농가명·도·시군 등 식별자는 피처에서 제외(환경 통계만) · 연도별 제각각인 CO₂ 컬럼명 표준화 후 결합


모델

LogisticRegression · RandomForest · XGBoost 비교 → 베스트 선정(로지스틱은 StandardScaler 파이프라인)

평가 3검

Test · StratifiedKFold · GroupKFold(연도+농가+작기) — '처음 보는 농가'로 정직하게 평가

트리 부스팅이 선형을 압도




로지스틱 0.33 →
XGBoost 0.68

세 모델 test 비교 — 선형(로지스틱 F1 0.33) 대비 트리 기반(RF 0.70 · XGBoost 0.68)이 압도적. 환경↔작물 관계가 비선형임을 시사. RF·XGB는 GroupKFold F1 0.496 vs 0.492로 통계적 동률.

RF·XGB 동률(std 0.04 이내) → 표데이터 관례·단년 베스트와 동일 모델 고정('데이터 양 효과'만 비교) 위해 XGBoost 채택

★ 랜덤 0.77 vs 농가분리 0.41 — 36%p 격차




SKF 0.77 → GKF 0.41

평가 3겹(2022 단년) — ① Test 0.78 ② StratifiedKFold 0.77(낙관적, 같은 농가가 train·test에 섞임) ③ GroupKFold 0.41(현실적, 처음 보는 농가). 랜덤 분리는 '농가·작기 고유 패턴'을 외워 성능을 과대평가한다.

정직한 0.41이 낙관적 0.77보다 가치 있다 — '한 숫자만 믿지 말 것'의 실증. 이 36%p 격차를 다년(2022~24) 결합으로 18%p까지 완화(→ 12p)


무엇이 작물을 가르는가 — 내부 온·습도



내부 온도·습도가 핵심 신호

RandomForest 기준 환경 피쳐 기여도 — 내부 온도·습도가 작물 구분의 핵심 신호. 내부 온도 계열(평균·최저·최고)은 상관 0.8↑로 다중공선성이 있으나 트리 모델은 견딘다.


잘 맞는 작물 · 약한 작물



참외 0.86 ↔ 수박 0.48

XGBoost 혼동행렬 — 잘 구분: 참외 0.86 · 파프리카 0.78 · 딸기 0.76. 약함: 수박 0.48 · 국화 0.56(표본 적음). 불균형이 소수 작물 성능으로 그대로 드러난다.

★ 데이터를 늘리니 더 정확해졌다 — 단년 vs 다년



**macro-F1 0.439 →
0.512 (+0.073)**

학습 데이터를 2022 단년(3.3만) → 2022~24 다년(11.6만, 3.5배)으로 확장. 공통 8작물을 동일 GroupKFold로 비교하니 macro-F1 0.439 → 0.512(+0.073), 누수 격차도 36%p → 18%p로 완화.

데이터 적던 작물일수록 효과 큼 — 방울토마토 +0.24·오이 +0.18·가지 +0.14, 수박은 신규 커버. 재현: `python src/ml/compare_years.py`

막혔던 곳들 — ML 트러블슈팅

문제	원인	해결
랜덤 F1 0.67인데 새 농가엔 폭락	같은 농가·작기가 train·test에 섞여 고유 패턴 암기(간접 누수)	GroupKFold(연도+농가+작기)로 0.49 정직 평가
연도별 CO ₂ 컬럼명이 제각각	잔존이산화탄소(CO2) / 잔존 CO2 ... 표기 상이	표준화 매핑 후 3개년 결합
다년 결합 시 작물 수 8→9 불공정 비교	클래스 수가 달라 macro-F1 직접 비교 불가	공통 8작물 per-class·동일 GroupKFold로 통제
정확도는 높는데 소수 작물을 놓침	25배 불균형(방울토마토 ≫ 수박)	F1(macro)·per-class recall 중심 평가

성과 종합 & 배운점

항목	지표	값
베스트 모델	XGBoost test F1(macro)	0.68
정직한 일반화	GroupKFold F1(새 농가)	0.49
데이터 누수	랜덤 vs 농가분리 격차	18%p
다년 결합 효과	공통 8작물 macro-F1	+0.073
커버 작물	단년 8종 → 다년	9종

배운점

- 데이터 누수는 실데이터에서 더 교묘하다 — GroupKFold(그룹 단위 평가)가 필수
- 정직한 0.49가 낙관적 0.67보다 가치 있다 — 평가 설계가 모델만큼 중요
- 데이터를 늘리면 누수에 덜 취약 — 단년 36%p → 다년 18%p (다양성이 과적합 완화)



배포: Streamlit (app/phase1_ml.py) — 환경 슬라이더 → 작물 예측·신뢰도 Top3 · 라이브 데모 <https://smartfarm-ai.streamlit.app/>

표를 못 넘는 일을 딥러닝으로 — 잎 진단 + 시계열

환경값 → 작물 분류(ML) → 잎 사진 → 병해 진단(CNN·YOLO) → 환경 흐름 예측(LSTM)

2-1 전이학습

토마토 잎 3분류(정상·잎곰팡이·황화잎말이) — 픽셀 패턴은 표로 못 만든다 → CNN

2-2 설명·검출

Grad-CAM 진단 근거 시각화 + YOLO 병해 잎 위치 검출

2-3 시계열

다변량·다년 LSTM으로 다음날 환경 예측 — 시점 간 의존

2-4 일관성

Phase 1의 데이터 양 효과가 DL(시계열)에서도 재현되는지 확인

관통 🌱 같은 작물(토마토)을 ML → DL → LLM으로 관통 · 📈 '데이터 누수·데이터 양 효과' 교훈을 비전·시계열로 확장